Otomatik Makale Puanlamasında Dilbilimsel Özellik Zenginleştirmesi: Hibrit DeBERTa Yaklaşımı

İsmail Görkem Ulaş
Bilgisayar Mühendisliği Bölümü
Gazi Üniversitesi, Ankara, Türkiye
21118080007

***Abstract*—Otomatik Makale Puanlaması (Automated Essay Scoring, AES), doğal dil işleme alanında eğitime doğrudan katkı sağlayan bilindik uygulamalardan biridir. Bu çalışma yorumlanabilir dilbilimsel özelliklerin — hata yoğunluğu, sözcüksel çeşitlilik, sözdizimsel karmaşıklık ve discourse bağlacı kullanımı — transformer tabanlı modelleri zenginleştirip zenginleştiremeyeceğini test etmeyi amaçlamıştır. Learning Agency Lab Automated Essay Scoring 2.0 adlı Kaggle yarışmasından veri seti kullanılarak yaklaşık 17.000 tane, öğrenciler tarafından yazılmış argümantatif deneme/makale 1–6 ölçeğinde puanlanmaktadır. Önce sistematik bir dilbilimsel özellik analizi (Amaç 1) yapılıp, ardından bu özellikler hibrit DeBERTa-base modeline entegre edildi (Amaç 2). Baseline DeBERTa-base modeli 0,757 Quadratic Weighted Kappa (QWK) değeri elde etmiştir. DeBERTa'nın [CLS] token temsiliyle 7 boyutlu dilbilimsel özellik vektörüyle birlikte kullanan hibrit modelse 0,753 QWK elde etmiştir. Ablasyon analizi, dilbilimsel özelliklerinden hiçbirinin kategorisinin DeBERTa'nın örtük olarak yakaladığının ötesinde istatistiksel olarak anlamlı ek sinyal oluşturmadığını gösterdi. Bu bulgular, gelişmiş büyük ön-eğitimli dil modellerinin insan değerlendiricilerin dikkat ettiği dilbilimsel kalite sinyallerini zaten etkili olarak kodladığını göstermektedir.**

***Index Terms*—Otomatik Makale Puanlaması, DeBERTa, Dilbilimsel Özellikler, Doğal Dil İşleme, Quadratic Weighted Kappa**

I. Giriş

Eğitimde değerlendirme süreci, öğrencilerin gelişimlerini izleyebilmek ve geri bildirim sağlamak açısından önemli bir rol oynar. Ama insan değerlendiricilerden oluşan geleneksel puanlama süreci zaman alıcı, maliyetli ve değerlendiriciler arası tutarsızlıklara açık bir yapıya sahiptir [1]. Bu sorunlara çözüm olarak geliştirilen Otomatik Makale Puanlama (AES) sistemleri, özellikle de büyük ölçekli standart sınavlarda veya çevrimiçi eğitim platformlarında giderek daha yaygın kullanılmaktadır.

AES alanındaki erken çalışmalar, e-rater [1] ve Intelligent Essay Assessor gibi sistemleri kapsayan kural tabanlı ve özellik mühendisliğine dayalı yaklaşımlara dayanırdı. Bu sistemler dilbilgisel karmaşıklık, söz varlığı genişliği ve metin uzunluğu gibi yüzeysel özellikleri kullanırdı. Derin öğrenmenin yaygınlaşmasıyla birlikte özellikle de BERT ve onun türevi modellerin [2] ince ayar yapılmasıyla elde edilen uçtan uca yaklaşımlar, kural tabanlı sistemleri büyük ölçüde geride bırakmıştır. Günümüzde DeBERTa [3] ve RoBERTa [4] gibi büyük ön-eğitimli modeller, çeşitli AES kıyaslama veri setlerinde en yüksek performansı sergilemektedir.

Bu gelişmeye karşın, transformer tabanlı yaklaşımlar iki temel sınırlılık taşımaktadır. Bunlardan ilki yorumlanabilirliktir yani model hangi dilsel özelliklerin yüksek puan almasına katkıda bulunduğunu açıkça ortaya koymamaktadır. İkincisiyse insan değerlendiricilerin bilinçli olarak dikkat ettiği spesifik dil bilimsel boyutların, denetimsiz öğrenilen temsillerde ne ölçüde kodlandığının belirsiz kalmasıdır. Holistic Scoring Rubric incelendiğinde, değerlendiricilerin makaleyi yalnız içerik açısından değil; aynı zamanda fikrin gelişimi, argümanın tutarlılığı, sözcük seçimi ve dilbilgisel doğruluk gibi çok boyutlu ölçütlere göre de değerlendirdiği görülmektedir.

Bu çalışma, söz konusu iki sınırlılığı gidermek amacıyla dilbilimsel özellik mühendisliğini transformer tabanlı modelle birleştiren hibrit bir yaklaşım önermektedir. Temel motivasyon, transformer modelinin zaten öğrendiği bilginin ötesine geçerek insan değerlendiricilerin puanlamada kullandığı somut dilsel ipuçlarını sayısal sinyallere dönüştürmek ve bu sinyallerin modele katkısını deneysel olarak ölçmektir.

Çalışmanın katkıları üç başlık altında özetlenebilir. Birincisi, AES rubriğiyle doğrudan ilişkilendirilebilen dört kategoride yedi dilbilimsel özellik sistematik biçimde çıkarılıp tek yönlü ANOVA aracılığıyla her birinin skor grupları arasındaki istatistiksel ayırt edici yeteneği kanıtlanmıştır. Bu analiz, ham makale metninde ölçülebilir kalite sinyallerinin varlığını verisel olarak belgelemektedir. İkincisi, söz konusu özellikler DeBERTa-base modelinin [CLS] token çıktısıyla birleştirilerek hibrit bir model mimarisi oluşturulmuş ve baseline modelle adil bir karşılaştırma yapılmıştır. Üçüncüsü, çıkarım zamanında özellik grubu sıfırlama yöntemiyle gerçekleştirilen ablasyon analizi, hangi dilbilimsel kategorinin transformer temsillerine göre artıklıktan arındırılmış en fazla bilgi katkısı sağladığını deneysel olarak ölçmektedir. Tüm kod ve özellik çıkarma pipeline ı yeniden üretilebilirlik ilkesine göre hazırlanmıştır.

II. İlgili Çalışmalar

A. Otomatik Makale Puanlaması

AES araştırmaları üç temel paradigma etrafında şekillenmiştir. İlk dönem çalışmalar özellik mühendisliğine dayanmakta olup Attali ve Burstein [1] tarafından geliştirilen e-rater

sistemi bu dönemin en kapsamlı örneğidir. Sistem sözcüksel karmaşıklık, dilbilgisel hata sayısı, discourse yapısı ve argüman organizasyonu gibi 50'den daha fazla özelliği birleştirerek puanlama yapmaktadır. Özellik tabanlı yaklaşımların temel avantajı yorumlanabilirliktir; ancak bu özellikler elle tasarlandığından kapsam ve genellenebilirlik açısından sınırlı kalmaktadır. Bu sınırlılıkları aşmak amacıyla Taghipour ve Ng [5], LSTM modelinin ham metinden temsil öğrenerek insan değerlendiricilerle yüksek korelasyon sağladığını göstermiş ve derin öğrenme yaklaşımlarının AES alanındaki etkinliğiniyse kapsamlı biçimde ortaya koymuştur.

Transformer modellerinin yaygınlaşmasıyla birlikte AES'te BERT tabanlı yaklaşımlar hâkim konuma gelmiştir. Yang ve ark. [6], ön-eğitimli dil modellerini regresyon ve sıralama hedeflerini birleştirerek ince ayar yapmanın EMNLP 2020 kıyaslamalarında performansı belirgin biçimde artırdığını göstermiştir. Wang ve ark. [7], BERT ile çok ölçekli makale temsili öğrenimini birleştirerek ASAP kıyaslama veri setinde rekabetçi sonuçlar elde etmiştir. Ridley ve ark. [8], discourse özellikleri ile BERT temsillerinin kombinasyonunun her iki yaklaşımı da geride bıraktığını ortaya koymuş; bu bulgu, bu çalışmadaki hibrit tasarıma doğrudan motivasyon sağlamıştır. Yarışmanın birinci çözümü Laubscher [9], iki aşamalı ön-eğitim ve ince ayar stratejisi ile DeBERTa-large toplu modellerini kullanan bu yaklaşımda yalnızca sayısal özellik vektörleriyle çalışan gradyan artırmalı karar ağaçlarının zayıf performans sergilediğini raporlamıştır; bu bulgu çalışmamın deneysel bulgularıyla örtüşmektedir. Mevcut çalışma bu literatürden şu açıdan ayrışmaktadır: transformer temsillerini zenginleştiren dilbilimsel özelliklerin modele gerçekten ek bilgi katkısı sağlayıp sağlamadığını deneysel olarak sorgulayan sistematik bir ablasyon analizi sunmaktadır.

B. Ön-Eğitimli Transformer Modelleri

Vaswani ve ark. [10] tarafından önerilen transformer mimarisi, öz-dikkat mekanizmasını dizilim modellemesinin baskın paradigması olarak yerleştirmiş ve tekrarlayan ağların NLP'deki hâkimiyetine son vermiştir. Çoklu kafa öz-dikkati sayesinde transformer, uzun mesafeli bağımlılıkları sabit sayıda işlemle modelleyebilmekte ve bu özellik uzun argümantatif metinlerin işlenmesinde kritik avantaj sağlamaktadır. BERT [2], maskeli dil modeli ön-eğitimi aracılığıyla bu yaklaşımı genişletmiş ve ince ayar ile görevlere uyarlanabilir genel amaçlı bir temsil öğrenimi çerçevesi sunmuştur. [CLS] token'ının sınıf temsili olarak kullanımı, BERT'in cümle ve belge düzeyinde sınıflandırma görevlerindeki başarısının temelini oluşturmakta olup bu çalışmada da bu yaklaşım benimsenmiştir.

RoBERTa [4], daha büyük mini-batch boyutları, daha uzun eğitim ve dinamik maskeleme gibi optimize edilmiş ön-eğitim prosedürleriyle BERT'i geliştirmiş ve birçok kıyaslama veri setinde BERT'i gerisinde bırakmıştır. DeBERTa [3], içeriği ve konumu ayrı ayrı kodlayan ayrıştırılmış dikkat mekanizması sayesinde bağlamsal temsilleri daha da güçlendirmiş ve SuperGLUE kıyaslamasında en iyi sonuçları elde etmiştir. Mevcut AES yarışmasının lider çözümlerinin tamamına yakını DeBERTa'yı omurga model olarak kullanmaktadır. Önerilen çalışma bu modellerden farklı olarak DeBERTa temsilini salt sınıflandırma amacıyla kullanmakla yetinmemekte; rubrik odaklı dilbilimsel sinyal vektörüyle birleştirerek yorumlanabilirlik katmanı eklemeyi denemektedir.

C. Metin Değerlendirmesinde Dilbilimsel Özellik Mühendisliği

Dilbilimsel özellik mühendisliği, metin kalitesi değerlendirmesinde köklü bir geçmişe sahiptir. Vajjala [11], sözdizimsel karmaşıklık ölçütleri, sözcüksel yetkinlik indeksleri ve sözcük türü dağılımlarını kapsayan zengin bir dilbilimsel özellik setinin anadili İngilizce olmayan öğrenci makalelerinin değerlendirilmesinde rekabetçi performans sergilediğini ve yorumlanabilirlik açısından önemli avantajlar sunduğunu göstermiştir. McCarthy ve Jarvis [12], MTLD metriğini sözcüksel çeşitlilik ölçümünde metin uzunluğundan bağımsız ve güvenilir bir araç olarak doğrulamıştır; bu metrik önerilen çalışmada TTR'ye ek olarak kullanılmaktadır.

Okunabilirlik değerlendirmesi alanındaki çalışmalar tamamlayıcı kanıtlar sunmaktadır. Zeng ve ark. [13], ön-eğitimli temsillerin yumuşak dilbilimsel etiketlerle birleştirilmesinin otomatik okunabilirlik değerlendirmesini iyileştirdiğini EMNLP 2022'de göstermiştir. Lee ve Vajjala [14], elle hazırlanmış dilbilimsel özelliklerle zenginleştirilmiş bir transformer modelinin okunabilirlik kıyaslamalarında her iki bileşeni tek başına kullanmaktan daha iyi performans sergilediğini ortaya koymuştur. Bu bulgular, dilbilimsel özelliklerin transformer temsillerine tamamlayıcı bilgi katkısı sağlayabileceğine işaret etmektedir. Mevcut çalışma bu hipotezi AES bağlamında sınamakta ve ablasyon analizi aracılığıyla her özellik kategorisinin artımlı katkısını deneysel olarak ölçmektedir.

III. YÖNTEM

A. Veri Seti

Bu çalışmada kullanılan veri seti, Learning Agency Lab — Automated Essay Scoring 2.0 Kaggle yarışmasından [15] elde edilmiştir. Veri seti, Persuade rubriğine göre 1–6 ölçeğinde bütünsel olarak puanlanmış 17.307 öğrenci tarafından yazılmış argümantatif makaleyi kapsamaktadır. Makaleler 8–12. sınıf düzeyindeki öğrenciler tarafından kaleme alınmış olup beş farklı yazma görevini (prompt) kapsamaktadır. Bu görevler arasında sürücüsüz arabalar, Mars yüzeyindeki yapılar ve Venüs gezegeninin keşfi gibi tartışmalı konularda argümantatif yazı üretme görevleri yer almaktadır. Her makale yalnızca tam metin ve bütünsel skor bilgisi içermekte; yazar kimliği, sınıf düzeyi veya demografik bilgi gibi ek metadata sağlanmamaktadır.

Skor dağılımı belirgin biçimde dengesizdir: skor 3 ve 4 birlikte tüm makalelerin yaklaşık %59'unu oluştururken, skor 6 yalnızca 156 makaleyle (%0,9) temsil edilmektedir. Bu dengesizlik model eğitimini doğrudan etkilemekte ve özellikle uç skor sınıflarında tahmin performansını düşürmektedir. Sözcük sayısı istatistikleri incelendiğinde ortalama makale uzunluğunun 368 kelime (standart sapma: 150, minimum: 150,

maksimum: 1.656) olduğu görülmektedir. Skor grubu bazında ortalama uzunluklar ise skor 1 için 268, skor 6 için 769 kelime olarak hesaplanmıştır; bu durum makale uzunluğunun skor ile güçlü pozitif ilişki içinde olduğuna işaret etmektedir. Bununla birlikte uzunluk, kalite yerine içerik miktarını yansıtabileceğinden modelin bu sinyali aşırı öğrenmesi riski göz önünde bulundurulmalıdır.

Veri seti iki alt popülasyondan oluşmaktadır: Persuade 2.0 korpusundan alınan yaklaşık 13.000 eski makale ve yarışmaya özgü yaklaşık 4.500 yeni makale. Birinci çözüm analizleri [9], iki alt popülasyon arasında puanlama kriterleri açısından sistematik farklılıklar bulunduğuna işaret etmektedir. Bu dağılım kayması (distribution shift) problemi, AES sistemlerinin genellenebilirliği açısından önemli bir zorluk oluşturmaktadır. Mevcut çalışmada veri alt popülasyonları arasında ayrım yapılmamış; tüm eğitim verisi tek bir havuzda kullanılmıştır.

B. Dilbilimsel Özellik Çıkarma (Amaç 1)

Her makale için dört rubrik odaklı kategoride yedi özellik çıkarılmıştır. Özellik çıkarma pipeline'ı tamamen Python NLP ekosistemi üzerinde çalışmakta olup harici API veya ücretli servis kullanımı gerektirmemiştir.

Hata Yoğunluğu. Dilbilgisel ve yazım hataları `language_tool_python` kütüphanesi aracılığıyla LanguageTool 6.8 motoru kullanılarak tespit edilmiştir. LanguageTool, kural tabanlı bir dilbilgisi denetleyicisi olup İngilizce için 1.000'den fazla dilbilgisi ve yazım kuralını kapsamaktadır. Hata yoğunluğu, tespit edilen hata sayısının toplam kelime sayısına oranı olarak hesaplanmakta ve böylece makale uzunluğundan bağımsız karşılaştırılabilir bir ölçüt elde edilmektedir. 17.307 makalenin tamamı için özellik çıkarma işlemi Kaggle Notebook CPU ortamında yaklaşık 4 saat sürmüştür.

Sözcüksel Çeşitlilik. İki tamamlayıcı metrik hesaplanmıştır. Type-Token Ratio (TTR), benzersiz sözcük türlerinin toplam token sayısına oranını ölçmektedir. TTR metin uzunluğuyla sistematik olarak düştüğünden uzun makalelerde yapay olarak düşük değerler üretmektedir. Bu uzunluk yanılsamasını gidermek için McCarthy ve Jarvis [12] tarafından geliştirilen MTLD (Measure of Textual Lexical Diversity) metriği 0,72 eşik değeriyle ek olarak hesaplanmıştır. MTLD, metni soldan sağa tarayarak TTR'nin eşik değerinin altına düştüğü noktaları faktör sınırı olarak işaretlemekte ve elde edilen faktör sayısına dayalı bir çeşitlilik skoru üretmektedir.

Sözdizimsel Karmaşıklık. `spaCy`'nin `en_core_web_sm` modeli kullanılarak her makale için ortalama cümle uzunluğu, cümle uzunluğu standart sapması ve ortalama bağımlılık ağacı derinliği hesaplanmıştır. Bağımlılık ağacı derinliği, her token için sözdizimsel kökten yukarı yönlü gezinti ile elde edilmekte ve cümlenin hiyerarşik karmaşıklığını sayısal olarak temsil etmektedir. Derin ağaçlar gömülü yan cümlecik yapılarına işaret ederken sığ ağaçlar basit koordinasyon yapılarına karşılık gelmektedir. Hesaplama süresini kısaltmak amacıyla bağımlılık analizi makale başına en fazla üç cümleyle sınırlandırılmıştır.

Discourse Bağlantısı. 13 discourse bağlacı ve geçiş ifadesinin (*however, therefore, furthermore, moreover, consequently, nevertheless, in conclusion, in contrast, on the other hand, for example, for instance, in addition, as a result*) geçiş sıklığı makale uzunluğuna normalize edilerek discourse bağlacı oranı elde edilmiştir. Bu özellik, argümantatif makalelerde fikir geçişlerinin ne ölçüde açıkça işaretlendiğini yansıtmaktadır.

Yedi özelliğin tamamı modele entegrasyon öncesinde `StandardScaler` ile standartlaştırılmıştır. Standartlaştırma, farklı birimlere sahip özelliklerin (örn. hata oranı ile kelime sayısı) model eğitiminde eşit ağırlıkla değerlendirilmesini sağlamaktadır.

C. Baseline Model

Baseline modeli, 6-sınıf dizi sınıflandırması için ince ayar yapılmış DeBERTa-v3-base modelidir. Makaleler maksimum 512 token uzunluğuyla tokenize edilmiştir. Eğitimde AdamW optimizer, 2×10^{-5} öğrenme hızı, 0,01 ağırlık azalması ve %10 doğrusal ısınmalı kosinüs öğrenme hızı çizelgesi kullanılmıştır. Eğitim Kaggle T4 GPU'da 2 epoch ve batch boyutu 4 ile gerçekleştirilmiştir.

D. Hibrit Model

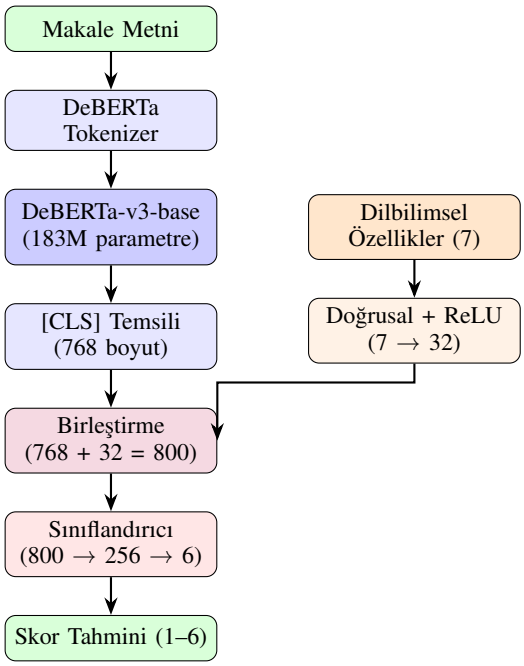


Fig. 1. Hibrit model mimarisi. DeBERTa'nın [CLS] token temsili, küçük bir ileri besleme ağından geçirilen dilbilimsel özellik vektörüyle birleştirilerek sınıflandırma başlığına verilmektedir.

Hibrit model, DeBERTa'nın [CLS] token temsilini (768 boyut) 7 boyutlu standartlaştırılmış dilbilimsel özellik vektörüyle birleştirerek genişletmektedir. Dilbilimsel özellikler önce doğrusal katman (7→32), ReLU aktivasyonu ve dropout (p=0,1) içeren küçük bir ileri besleme ağından geçirilmektedir. Birleştirilen temsil (800 boyut) ardından doğrusal katman

(800→256), ReLU, dropout (p=0,1) ve son doğrusal katman (256→6) içeren sınıflandırma başlığından geçirilmektedir.

E. Değerlendirme

Birincil değerlendirme metriği, zaten yarışmanın da resmi metriği olan Quadratic Weighted Kappa'dır (QWK). Skor etiketine göre tabakalı 2-katlı çapraz doğrulama üzerinden ortalama QWK raporlanmaktadır. Skor sınıfı bazında F1 skoru da dengesiz skor dağılımı genelinde model davranışını karakterize etmek amacıyla raporlanmıştır.

IV. Deneysel Tasarım

A. Araştırma Soruları

Bu çalışma iki araştırma sorusunu ele almaktadır:

AS1 (Amaç 1): Rubrik odaklı dilbilimsel özellikler, makale skor grupları arasında istatistiksel olarak anlamlı ayırt edici güç sergiliyor mu?

AS2 (Amaç 2): Bu özellikler, hibrit modele entegre edildiğinde DeBERTa'nın örtük temsillerinin ötesinde ek sinyal sağlıyor mu?

B. Amaç 1: Özellik Analizi Protokolü

Dilbilimsel özelliklerin ayırt edici gücünü değerlendirmek amacıyla tek yönlü ANOVA (Analysis of Variance) testi uygulanmıştır. ANOVA, ikiden fazla grup ortalaması arasında istatistiksel olarak anlamlı farklılık bulunup bulunmadığını test etmekte olup sıfır hipotezi tüm skor gruplarının ilgili özellik açısından aynı ortalamaya sahip olduğunu varsaymaktadır. $p < 0,05$ eşiğinin altındaki p-değerleri istatistiksel anlamlılık göstergesi olarak kabul edilmiştir. F-istatistiği ise gruplar arası varyansın gruplar içi varyansa oranını ifade etmekte ve ayırt edici gücün büyüklüğünü göstermektedir.

Her özellik için skor grupları bazında dağılımlar kutu grafikleri aracılığıyla görselleştirilmiştir. Kutu grafiklerinde merkez çizgi medyanı, kutunun alt ve üst sınırları sırasıyla 25. ve 75. yüzdelik dilimleri, bıyıklar ise aykırı değer sınırlarını temsil etmektedir. Bu görselleştirme, yalnızca ortalama farklılıklarını değil dağılım şekillerini ve aykırı değer örüntülerini de görselleştirmektedir. Amaç 1 analizi, Amaç 2'den bağımsız olarak tamamlanabilir niteliktedir; dilbilimsel özellik seti ve istatistiksel analiz tek başına özgün bir katkı olarak değerlendirilebilir.

C. Amaç 2: Model Karşılaştırma Protokolü

Baseline ve hibrit modeller, özdeş hiperparametreler ve özdeş veri bölünmeleri altında eğitilerek adil bir karşılaştırma sağlanmıştır. Model değerlendirmesi için 2-katlı tabakalı çapraz doğrulama (stratified k-fold cross-validation) kullanılmıştır. Tabakalı bölünme, her katlama setinde skor dağılımının orijinal veri setiyle orantılı kalmasını garantilemekte ve özellikle azınlık sınıflarının (skor 6: 156 örnek) her katlamada temsil edilmesini sağlamaktadır. Rastgele tohum değeri (seed = 42) tüm deneylerde sabit tutularak yeniden üretilebilirlik sağlanmıştır.

Bireysel özellik kategorilerinin katkısını izole etmek amacıyla çıkarım zamanı ablasyon analizi uygulanmıştır. Bu yöntemde eğitilmiş hibrit modelin ağırlıkları değiştirilmeden, yalnızca ilgili özellik grubunun değerleri sıfırlanarak QWK'daki değişim ölçülmektedir. Yeniden eğitim gerektirmemesi sayesinde ablasyon analizi hesaplama açısından verimli olmakda ve özellik grubunun model kararlarına olan marjinal katkısını izole etmektedir. Dört özellik grubu sırayla test edilmiştir, bunlar: hata yoğunluğu, sözcüksel çeşitlilik (TTR + MTLD), sözdizimsel karmaşıklık (ortalama cümle uzunluğu + standart sapma + bağımlılık derinliği) ve discourse bağlacı oranı.

D. Uygulama Detayları

Tüm özellik çıkarma deneyleri lokal bir CPU makinesinde (Windows 11, Python 3.13, 16 GB RAM) gerçekleştirilmiştir. DeBERTa eğitimi ve değerlendirmesi Kaggle Notebooks platformunda NVIDIA Tesla T4 GPU (16 GB VRAM) kullanılarak yapılmıştır. Karma hassasiyet eğitimi (mixed precision training) bellek verimliliği için etkinleştirilmiş olup gradyan ölçekleme (gradient scaling) sayısal kararlılık sağlanmıştır. Model ağırlıkları her katlama için ayrı ayrı kaydedilmiş ve en yüksek doğrulama QWK değerini veren epoch'un ağırlıkları nihai değerlendirmede kullanılmıştır.

Özellik çıkarma aşamasında karşılaşılan temel pratik zorluk, LanguageTool motorunun işlem süresidir. Java tabanlı bu motor, her makale için bağımsız bir dilbilgisi denetimi gerçekleştirmekte ve 17.307 makalenin tamamı için yaklaşık 4 saat CPU süresi gerektirmiştir. Bu süreyi yönetmek amacıyla 1.000 makalelik aralıklarla ara kayıt (checkpoint) mekanizması uygulanmıştır. spaCy ile gerçekleştirilen sözdizimsel analiz ve MTLD hesaplaması ise toplam 20 dakikanın altında tamamlanmıştır. Tüm kod ve özellik çıkarma pipeline'ı yeniden üretilebilirlik ilkesine göre hazırlanmıştır.

V. Deneysel Sonuçlar

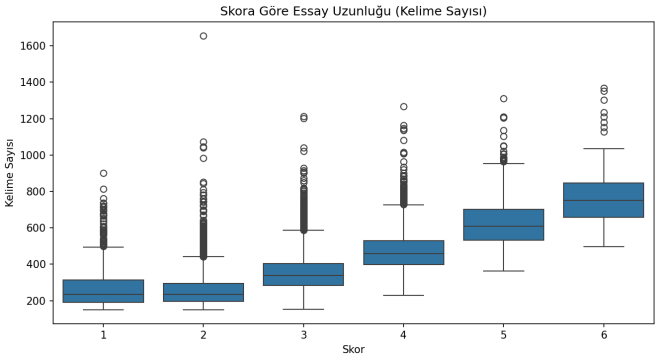


Fig. 2. Skora göre makale uzunluğu dağılımı. Skor arttıkça ortalama kelime sayısı monoton artmakta; skor 1 makalelerinde aykırı değer olarak çok uzun run-on/dragging cümleler gözlemlenmiştir.

A. Amaç 1: Dilbilimsel Özellik Analizi

Tablo I, skor grubu başına ortalama özellik değerlerini ve tek yönlü ANOVA sonuçlarını sunmaktadır. Yedi özelliğin tamamı skor grupları arasında istatistiksel olarak anlamlı farklılıklar

sergilemektedir (tümü için $p < 0,0001$). Hata yoğunluğu $F = 638,42$ ile en güçlü ayırt edici gücü göstermektedir.

TABLE I
DILBILIMSEL ÖZELLIKLER IÇIN ANOVA SONUÇLARI

Özellik	F-istatistiği	p-değeri
Hata Yoğunluğu	638,42	<0,0001
MTLD	24,40	<0,0001
Ort. Cümle Uzunluğu	56,69	<0,0001
Std. Cümle Uzunluğu	34,85	<0,0001
Bağımlılık Derinliği	35,62	<0,0001
Discourse Oranı	53,08	<0,0001
TTR	47,21	<0,0001

TABLE II
SKOR GRUPLARINA GÖRE ORTALAMA DILBILIMSEL ÖZELLIK DEĞERLERI

Özellik	Skor 1	Skor 2	Skor 3	Skor 4	Skor 5	Skor 6
Hata Yoğ.	0,089	0,067	0,051	0,038	0,027	0,022
MTLD	73,7	70,9	72,3	74,6	75,9	78,4
Ort. Cümle	28,0	22,8	20,4	20,5	21,3	22,8
Std. Cümle	11,7	10,0	9,2	9,1	9,3	10,0
Bağ. Der.	2,86	2,70	2,61	2,62	2,71	2,90
Disc. Oranı	0,001	0,002	0,002	0,002	0,002	0,004
TTR	0,570	0,553	0,509	0,477	0,453	0,434

Skor koşullu kutu grafikleri niteliksel olarak tutarlı eğilimler ortaya koymaktadır: hata yoğunluğu skor 1'den (ortalama 0,089) skor 6'ya (ortalama 0,022) monoton biçimde azalmakta; discourse bağlacı oranı ise skor 1'de neredeyse sıfırdan skor 6'da ölçülebilir pozitif bir değere yükselmektedir. TTR'nin skorla ters ilişki göstermesi, düşük puanlı makalelerin daha kısa olmasından kaynaklanan uzunluk yanılsamasına yorulmuştur. Ortalama cümle uzunluğunda ilgi çekici bir aykırı örüntü gözlemlenmektedir: skor 1 makaleleri en yüksek ortalama cümle uzunluğunu sergilemekte (27,97 kelime), bu durum noktalama işareti kullanmadan yazılmış ardışık cümlelerin varlığını yansıtmaktadır.

B. Amaç 2: Hibrit Model Sonuçları

Tablo III, her iki katlama için baseline ve hibrit model QWK skorlarını özetlemektedir. Baseline DeBERTa-base modeli 2-katlı çapraz doğrulama üzerinden ortalama 0,7579 QWK elde etmiştir. Bu değer, yarışma lider tablosundaki en iyi tek model sonuçlarının (0,83–0,84) altında kalmakla birlikte, 2 epoch ve sınırlı hiperparametre optimizasyonu göz önünde bulundurulduğunda makul bir başlangıç noktası oluşturmaktadır. Karşılaştırma amacıyla, yarışmanın birinci çözümü [9] 21 DeBERTa-large modeli, iki aşamalı eğitim ve sahte etiketleme stratejileri kullanarak 0,841 özel lider tablosu skoru elde etmiştir.

Hibrit model 0,753 ortalama QWK elde etmiş olup baseline değerinin (0,757) hafif altında kalmaktadır. $-0,0044$'lük fark ihmal edilebilir düzeydedir ve 2-katlı değerlendirmede beklenen varyans aralığı içinde kalmaktadır.

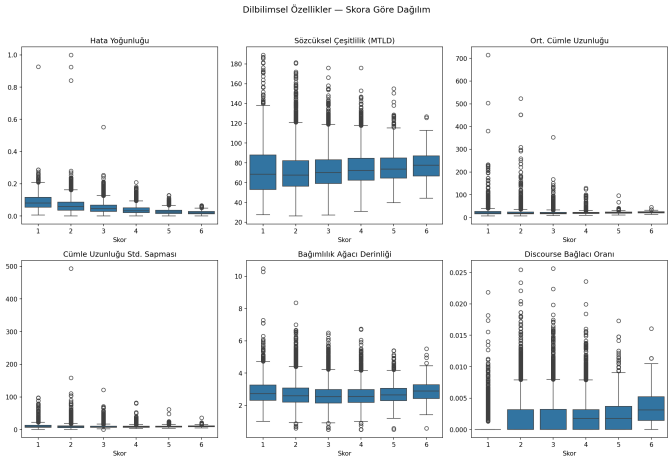


Fig. 3. Dilbilimsel özelliklerin skor gruplarına göre dağılımı. Hata yoğunluğu skor 1'den 6'ya monoton azalırken, discourse bağlacı oranı artış göstermektedir. TTR'deki ters ilişki uzunluk yanılsamasına yorulmuştur.

TABLE III
QWK SONUÇLARI: BASELINE VE HIBRIT MODEL KARŞILAŞTIRMASI

Model	Katlama 1	Katlama 2	Ortalama
DeBERTa Baseline	0,7552	0,7606	0,7579
Hibrit (DeBERTa + Dilb.)	0,7467	0,7603	0,7535
Fark	−0,0085	−0,0003	−0,0044

C. Ablasyon Analizi

Tablo IV, her özellik grubunun çıkarım zamanında sıfırlandığı ablasyon analizi sonuçlarını sunmaktadır.

TABLE IV
ABLASYON ANALIZI: HER ÖZELLIK GRUBUNUN KALDIRILMASININ ETKISI

Kaldırılan Özellik Grubu	QWK	Δ QWK
Hiçbiri (tam hibrit)	0,7466	—
Hata Yoğunluğu	0,7469	+0,0003
Sözcüksel Çeşitlilik	0,7465	−0,0001
Sözdizimsel Karmaşıklık	0,7467	+0,0002
Discourse Oranı	0,7466	+0,0000

Hiçbir özellik grubu kaldırıldığında anlamlı bir QWK değişimi gözlemlenmemektedir. Bu sonuç, DeBERTa'nın bağlamsal temsillerinin bu çalışmada elle hazırlanmış özelliklerin yakaladığı bilgiyi zaten kodlamış olduğunu göstermektedir.

D. Sınıf Bazında F1 Analizi

Tablo V, hibrit modelin Katlama 1 doğrulama seti üzerindeki sınıf bazında kesinlik, duyarlılık ve F1 değerlerini raporlamaktadır. Sınıf bazında F1 analizi ciddi bir sınıf dengesizliği etkisi ortaya koymaktadır: model skor 6 için F1 = 0,00 elde etmekte, yani en yüksek puanlı makalelerin hiçbirini doğru tahmin edememektedir. Bu durum, doğrulama setindeki yalnızca 31 skor 6 örneğinin model eğitimi için yetersiz

kaldığını ve modelin bu sınıfı büyük ihtimalle skor 4 veya 5 olarak yanlış sınıflandırdığını göstermektedir.

Skor 1 de düşük duyarlılık sergilemektedir (0,27): model düşük puanlı makaleleri çoğunlukla skor 2 veya 3 olarak tahmin etmektedir. Bu eğilim, skor 2 ve 3'ün eğitim verisine hâkim olmasından kaynaklanmakta olup model bu çoğunluk sınıflarına doğru sistematik bir önyargı geliştirmektedir. En yüksek F1 değerleri ise eğitim dağılımına hâkim olan skor 3 (F1 = 0,63) ve skor 4 (F1 = 0,62) için gözlemlenmektedir.

QWK metriğinin bu sınıf dengesizliği etkisini büyük ölçüde maskelediği dikkat çekmektedir. QWK, hataları karesel mesafeyle ağırlıklandırdığından komşu skor sınıfları arasındaki hataları hafifçe cezalandırmakta; bu durum skor 6 için F1 = 0,00 gibi ciddi bir başarısızlığın genel QWK değerine yansımasını sınırlamaktadır. Bu nedenle yüksek riskli AES uygulamalarında QWK'nın tek değerlendirme metriği olarak kullanılması yetersiz kalabilmekte ve sınıf bazında F1 gibi tamamlayıcı metriklerin raporlanması gerekmektedir.

TABLE V
SINIF BAZINDA SINIFLANDIRMA RAPORU (HIBRIT MODEL, KATLAMA 1)

Skor	Kesinlik	Duyarlılık	F1
1	0,76	0,27	0,40
2	0,71	0,53	0,60
3	0,60	0,67	0,63
4	0,54	0,73	0,62
5	0,38	0,39	0,38
6	0,00	0,00	0,00
Ağırlıklı Ort.	0,61	0,60	0,59

E. Tartışma

Sonuçlar iki temel bulguyu ortaya koymuştur. Birincisi, yedi dilbilimsel özelliğin tamamı skor grupları arasında istatistiksel olarak ayırt edicidir; bu durum rubrik odaklı sinyallerin ham makale metninde ölçülebilir olduğunu doğrulamaktadır. Özellikle hata yoğunluğunun $F = 638,42$ ile diğer özelliklerin çok üzerinde bir ayırt edici güç sergilemesi, yüzey düzeyindeki dilbilgisel kalite ile bütünsel skor arasındaki güçlü ilişkiyi somut biçimde ortaya koymaktadır. İkincisi ve beklenmeyen olanı, bu özelliklerin DeBERTa tabanlı hibrit modele entegre edildiğinde ölçülebilir bir ek değer sağlamamasıdır. Bu sonuç, DeBERTa'nın bağlamsal temsillerinin söz konusu kalite sinyallerini zaten örtük olarak kodlaması şeklinde yorumlanmıştır; bu yorum, ön-eğitimli dil modellerinin geniş bir dilbilimsel özellik yelpazesini yakaladığını gösteren literatürle [2] örtüşmektedir.

Bu bulgu, Ridley ve ark. [8] ile Lee ve ark. [14]'nın discourse ve okunabilirlik özelliklerinin transformer temsillerine tamamlayıcı katkı sağladığını gösteren bulgularıyla yüzeysel olarak çelişmektedir. Bu tutarsızlığın olası bir açıklaması, söz konusu çalışmalarda kullanılan görev ve veri setlerinin farklı özellikler taşımasıdır: okunabilirlik değerlendirmesi gibi görevlerde dilbilimsel özellikler daha belirleyici olabilirken argümantatif makale puanlamasında DeBERTa'nın büyük ölçekli ön-eğitim verisi bu sinyalleri zaten içselleştirmiş olabilir. Ayrıca hibrit modelin temsil düzeyinde basit birleştirme (concatenation) kullanması, dilbilimsel özelliklerin daha sofistike entegrasyon stratejileriyle — örneğin çok görevli öğrenme veya dikkat tabanlı özellik kapılama — daha etkin biçimde kullanılabileceği ihtimalini dışlamamaktadır.

Deneylerin yanıt vermediği çeşitli sorular mevcuttur. 2-epoch eğitim bütçesi ve 2-katlı değerlendirme, dilbilimsel özelliklerin küçük ama gerçek etkilerini gizliyor olabilecek bir varyans oluşturmaktadır. 5-katlı değerlendirme ve 3–5 epoch eğitim daha güvenilir tahminler sağlayacaktır. Sınıf dengesizliği problemi (skor 6: verinin %0,9'u) yapısal bir zorluk oluşturmakta olup gelecekteki çalışmalar sınıf ağırlıklı kayıp fonksiyonları veya SMOTE gibi aşırı örnekleme stratejilerini araştırmalıdır. Son olarak, veri setindeki iki alt popülasyon (Persuade ve yarışmaya özgü makaleler) arasındaki dağılım kayması problemi, puanlama kriterlerindeki sistematik farklılıkların modeli olumsuz etkileyip etkilemediğini araştırmak için ayrı bir analizi hak etmektedir. Bu bağlamda, gelecekteki çalışmaların sınıf ağırlıklı kayıp fonksiyonları ve daha uzun eğitim süreleriyle hibrit yaklaşımı yeniden değerlendirmesi önerilir.

VI. SONUÇLAR

Bu çalışma, yorumlanabilir rubrik odaklı dilbilimsel özelliklerin transformer tabanlı otomatik makale puanlamasını zenginleştirip zenginleştiremeyeceğini araştırmıştır. Hata yoğunluğu, sözcüksel çeşitlilik, sözdizimsel karmaşıklık ve discourse bağlantısı olmak üzere dört kategoride yedi özellik çıkarılmış ve tek yönlü ANOVA kullanılarak bu özelliklerin skor grupları arasındaki istatistiksel ayırt edici gücü kanıtlanmıştır. Ancak bu özelliklerin hibrit DeBERTa-base modeline entegrasyonu, 0,757 QWK değerindeki baseline'a kıyasla ölçülebilir bir iyileşme sağlamamıştır. Ablasyon analizi, hiçbir bireysel özellik kategorisinin DeBERTa'nın örtük temsillerinin ötesinde artıklıktan arındırılmış sinyal sağlamadığını doğrulamaktadır. Temel çıkarım, büyük ön-eğitimli dil modellerinin insan değerlendiricilerin dikkat ettiği dilbilimsel kalite boyutlarını etkili biçimde içselleştirdiği ve bu nedenle temsil düzeyinde açık elle hazırlanmış özellik zenginleştirmesini gereksiz kıldığıdır.

Çalışmanın pratik çıkarımları değerlendirilse, dilbilimsel özellik analizinin (Amaç 1) model geliştirmeden bağımsız olarak eğitim teknolojileri alanında doğrudan uygulanabilirliği bulunmaktadır. Hata yoğunluğu, sözcüksel çeşitlilik ve discourse bağlacı kullanımı gibi ölçütler, öğrencilere anlık ve yorumlanabilir geri bildirim sağlayan hafif yazma destek araçlarının temelindedir. Bu tür araçlar, büyük transformer modellerinin gerektirdiği hesaplama altyapısına ihtiyaç duymadan çalışabileceğinden düşük kaynaklı eğitim ortamlarında da kullanılabilir. Hibrit model çerçevesi ise transformer tabanlı

AES sistemlerinin yorumlanabilirliğini artırmaya yönelik gelecekteki araştırmalar için bir başlangıç noktası olabilir.

Etik Boyutlar. Otomatik makale puanlama sistemleri önemli etik boyutlar taşımaktadır. Birincisi, dengesiz veri setleri üzerinde eğitilen modeller — çalışmada en yüksek skor sınıfı için F1 = 0,00 ile gösterildiği üzere — eğitim verisinde yeterince temsil edilmeyen öğrencileri sistematik olarak dezavantajlı konuma düşürebilir. Bu durum özellikle anadili İngilizce olmayan öğrenciler ve azınlık gruplarından gelen bireyler için adalet kaygıları doğurmaktadır. İkincisi, şeffaflık ve hesap verebilirlik kritik öneme sahiptir: AES sistemleri yüksek riskli bağlamlarda kullanıldığında, öğrencilerin ve kurumların puanlamaya ilişkin yorumlanabilir açıklamalara erişim hakkı bulunmalıdır. Üçüncüsü, otomatik puanlamaya aşırı bağımlılık, eğitimsel değerlendirmede insan gözetimini azaltarak tarihsel puanlama verilerindeki önyargıları pekiştirebilir. AES sistemlerinin insan değerlendiricilerin yanında karar destek aracı olarak konumlandırılması bu sebeplerden önerilmektedir.

KAYNAKÇA

REFERENCES

[1] Y. Attali and J. Burstein, "Automated essay scoring with e-rater v.2.0," *Journal of Technology, Learning, and Assessment*, vol. 4, no. 3, 2006.

[2] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proceedings of NAACL-HLT*, 2019, pp. 4171–4186.

[3] P. He, X. Liu, J. Gao, and W. Chen, "DeBERTa: Decoding-enhanced BERT with disentangled attention," in *Proceedings of ICLR*, 2021.

[4] Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer, and V. Stoyanov, "RoBERTa: A robustly optimized BERT pretraining approach," *arXiv preprint arXiv:1907.11692*, 2019.

[5] K. Taghipour and H. T. Ng, "A neural approach to automated essay scoring," in *Proceedings of EMNLP*, 2016, pp. 1882–1891.

[6] R. Yang, J. Cao, Z. Wen, Y. Wu, and X. He, "Enhancing automated essay scoring performance via fine-tuning pre-trained language models with combination of regression and ranking," in *Findings of the Association for Computational Linguistics: EMNLP*, 2020, pp. 1560–1569.

[7] Y. Wang, C. Wang, R. Li, and H. Lin, "On the use of BERT for automated essay scoring: Joint learning of multi-scale essay representation," in *Proceedings of NAACL-HLT*, 2022.

[8] R. Ridley, L. He, X. Dai, S. Huang, and J. Chen, "Automated cross-prompt scoring of essay traits," in *Proceedings of AAAI*, vol. 35, no. 15, 2021, pp. 13 745–13 753.

[9] F. Laubscher, "1st place solution — trust CV (and LB a bit)," Kaggle Discussion, 2024. [Online]. Available: https://www.kaggle.com/competitions/learning-agency-lab-automated-essay-scoring-2/writeups/flg-1st-place-solution-trust-cv-and-lb-a-bit

[10] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.

[11] S. Vajjala, "Automated assessment of non-native learner essays: Investigating the role of linguistic features," *International Journal of Artificial Intelligence in Education*, vol. 28, pp. 79–105, 2018.

[12] P. M. McCarthy and S. Jarvis, "MTLD, vocd-D, and HD-D: A validation study of sophisticated approaches to lexical diversity assessment," *Behavior Research Methods*, vol. 42, no. 2, pp. 381–392, 2010.

[13] J. Zeng, Y. Xie, X. Yu, J. S. Y. Lee, and D.-X. Zhou, "Enhancing automatic readability assessment with pre-training and soft labels," in *Findings of the Association for Computational Linguistics: EMNLP*, 2022, pp. 4557–4568.

[14] B. W. Lee and J. Lee, "Pushing on text readability assessment: A transformer meets handcrafted linguistic features," in *Proceedings of EMNLP*, 2021.

[15] Learning Agency Lab, "Automated essay scoring 2.0," Kaggle Competition, 2024. [Online]. Available: https://www.kaggle.com/competitions/learning-agency-lab-automated-essay-scoring-2